

# GLOBAL TECH SALARY

Estudio basado en Análisis de Datos, Machine Learning y Deep Learning, utilizando el dataset de Global Tech Salary.



# Exploración Inicial

Exploración

Factores

Modelos

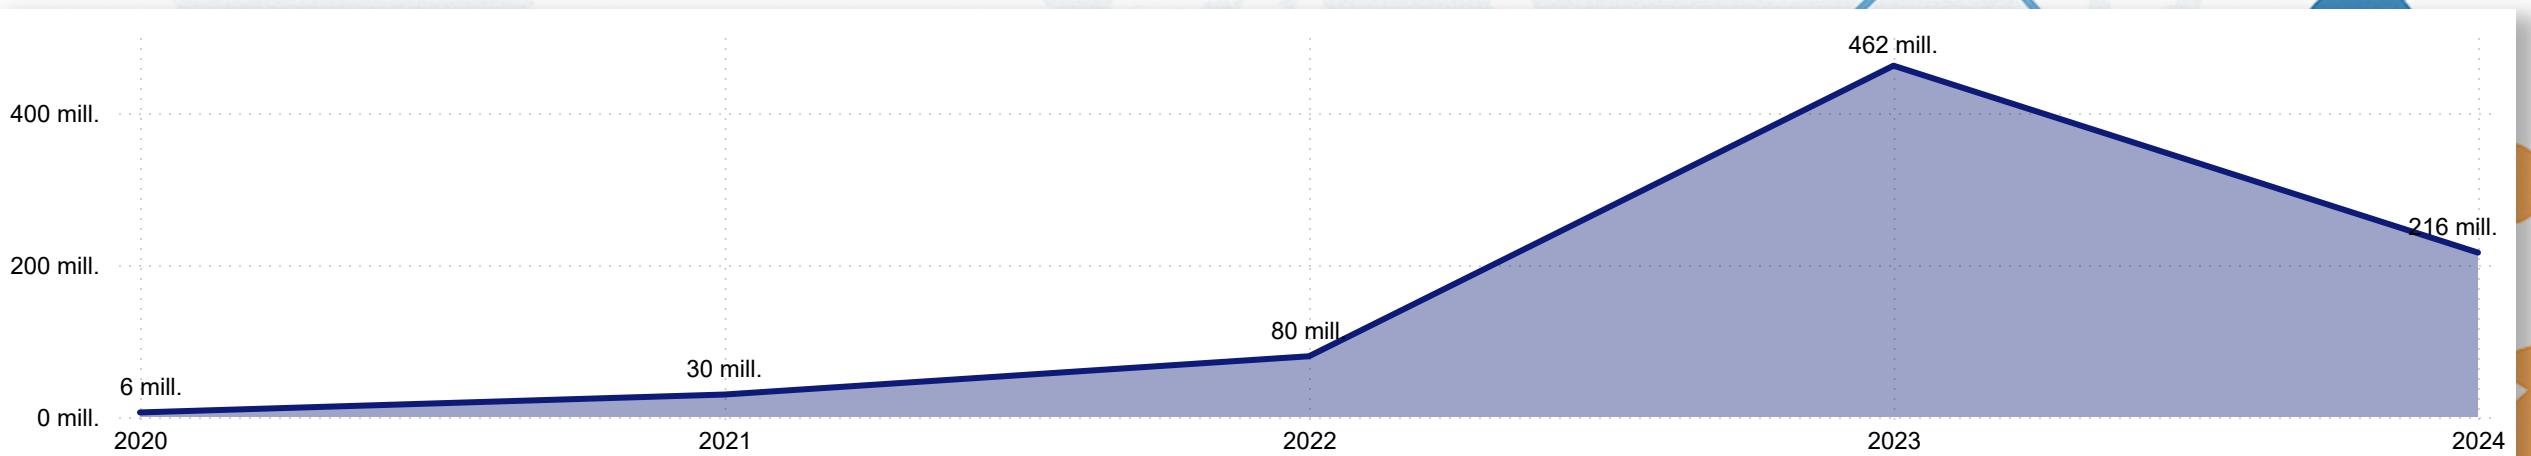


Cantidad de Registros 🔎  
**5.000**

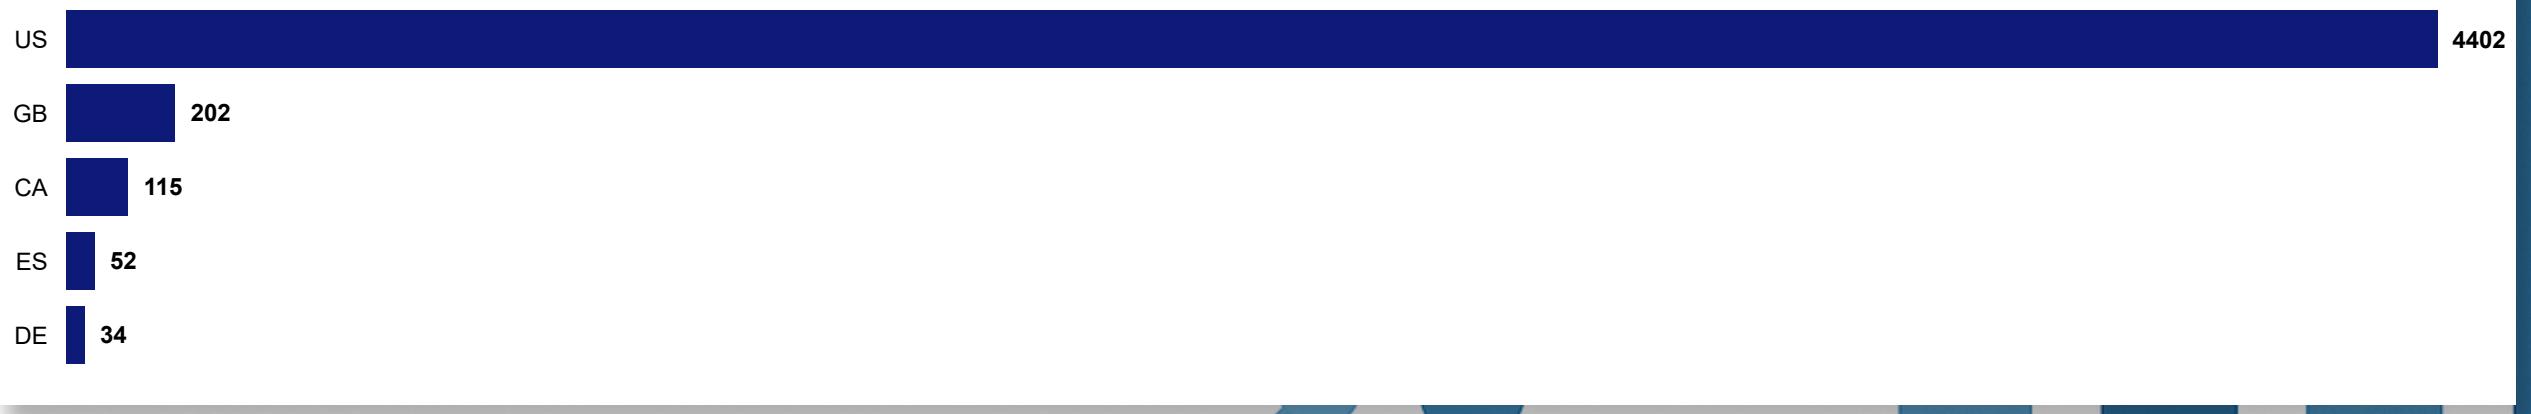
Mayor Representación 🏅  
**US**

Salario Promedio USD 💰  
**148.924**

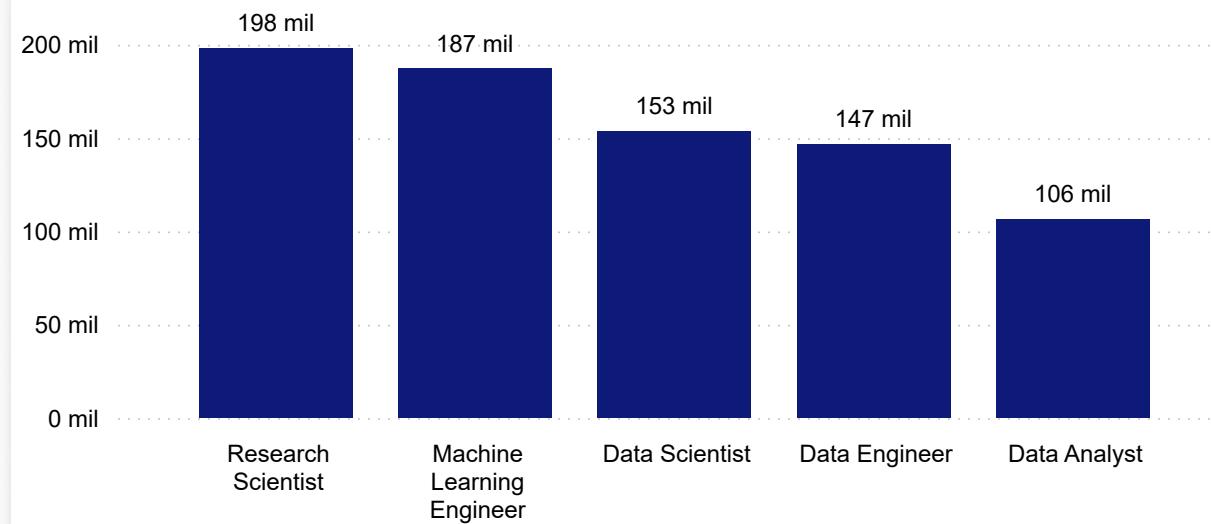
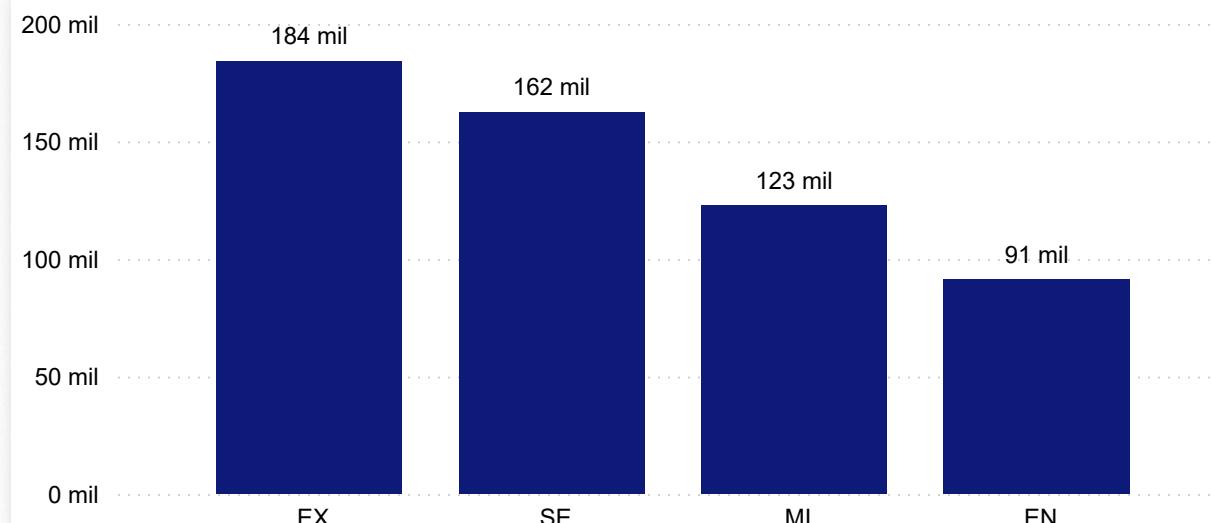
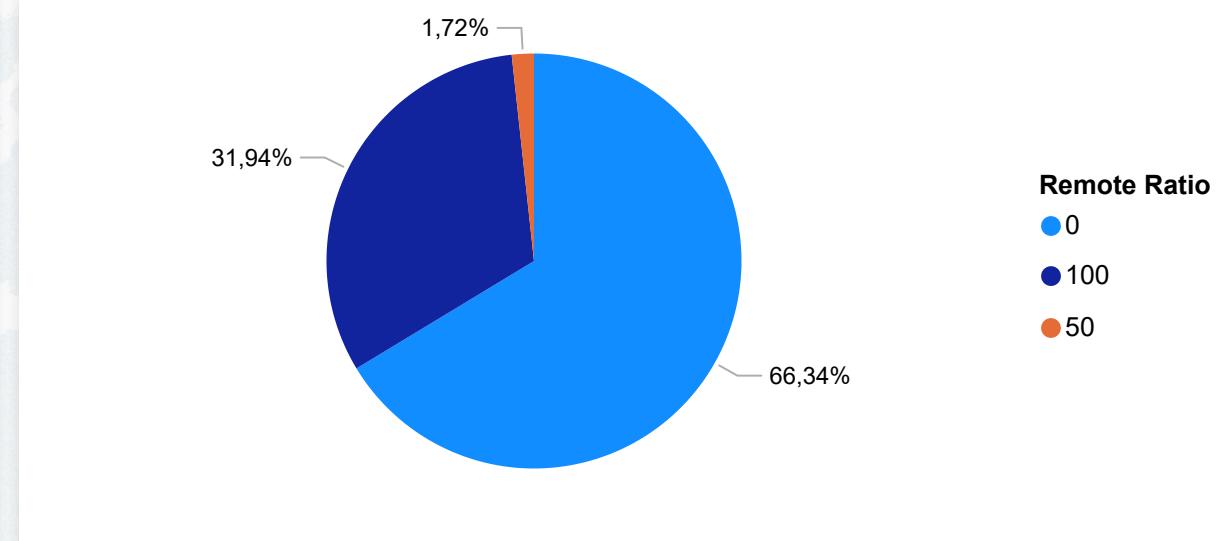
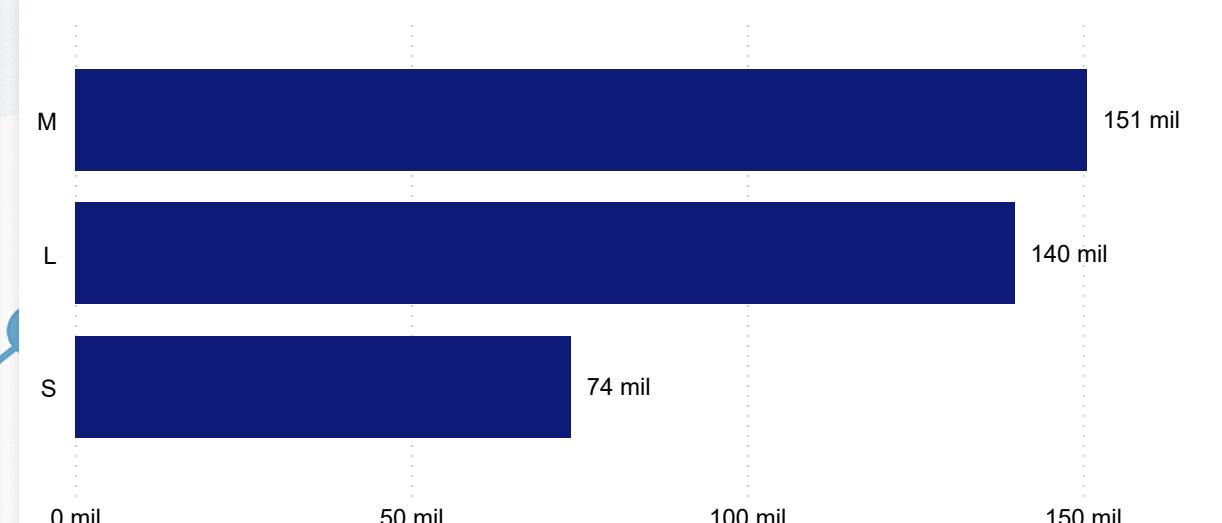
Salario a lo Largo del Tiempo📈⌚



Top 5 Países por Cantidad de Empleados 🏆



# Factores que afectan el Salario

[Exploración](#)[Factores](#)[Modelos](#)**Salario Promedio por Título** **Salario Promedio por Experiencia** **Distribución según Modalidad de Trabajo****Salario Promedio por Tamaño de la Empresa** 

# Modelos Predictivos

[Exploración](#)[Factores](#)[Modelos](#)

Modelo	MAE	MSE	R2
KNN	35.057,95	2E+015	0,18
Decision Tree	35.020,37	2E+015	0,18
Random Forest	34.711,18	2E+015	0,21
Linear Regression	34.220,59	2E+015	0,24
XGBoost	33.935,01	2E+015	0,25
Red Neuronal	33.732,78	2E+009	0,22

## Análisis de los Resultados

- El modelo con menor MAE fue la red Neuronal, con un valor aproximadamente de 33.732 USD, el mismo está seguido de XGBoost.
- Modelos como el KNN y el Decision Tree mostraron desempeños más bajos, con un R2 por debajo de 0.20.
- Concluimos que los modelos más complejos capturan mejor la relación entre las variables del dataset.

## Modelo Elegido - Red Neuronal

- La Red Neuronal mostró una buena estabilidad viendo los gráficos de pérdida y MAE, porque muestran una rápida convergencia en las primeras épocas.
- No se observa overfitting, teniendo en cuenta que la diferencia entre el error de entrenamiento y validación es mínima.
- Aplicar EarlyStopping fue una decisión adecuada para evitar el sobreentrenamiento, ya que a partir de la época 15, ambas métricas se estabilizan.

